Ejercicio 07 · Evaluación de impacto y auditoría de equidad

INF-8239 Ciencia de Datos II (UASD) · Unidad 04 · Integración de LAB11 y LAB12

Estudiante	Edwing Perez
Profesor	Edwin Ramón José Nolasco
Repositorio	https://github.com/edvvdev/unidad04-07
Caso	Riesgo territorial SINTÉTICO (640 registros) · no representa personas ni estadísticas reales de RD
Decisión	LIMITAR · piloto en modo REVIEW con revisión humana obligatoria y baseline sin modelo como camino operativo seguro
Estado del pipeline	REVIEW · fallan 3 puertas (ver sección 4)

1. Finalidad, interesados y proporcionalidad

Priorizar la revisión humana de casos con señal de riesgo territorial para orientar el esfuerzo de prevención (verificación en campo y acompañamiento). El sistema no decide: ordena la cola de revisión y aporta evidencia. El caso de negocio es didactic and synthetic: el dataset incluido es un caso territorial sintético que no representa personas, territorios ni estadísticas reales de República Dominicana.

Reparto rotativo por zona y severidad reportada, priorización manual de todas las alertas recibidas, o inversión en infraestructura y tiempo comunitario priorizado por criterios publicados y no por un modelo. Estas alternativas no usan datos individuales y por tanto evitan la exposición a datos sensibles.

Prohibido: Prohibido usar el modelo o su ranking para: decidir sanciones, sanciones administrativas o prohibiciones de cualquier tipo; abrir expedientes o imputar responsabilidades; distribuir fondos o recursos entre zonas según el ranking de riesgo; autorizar identificaciones, registros o vigilancia; puntuar a personas; y usar datos de la cola para entrenar otros sistemas.

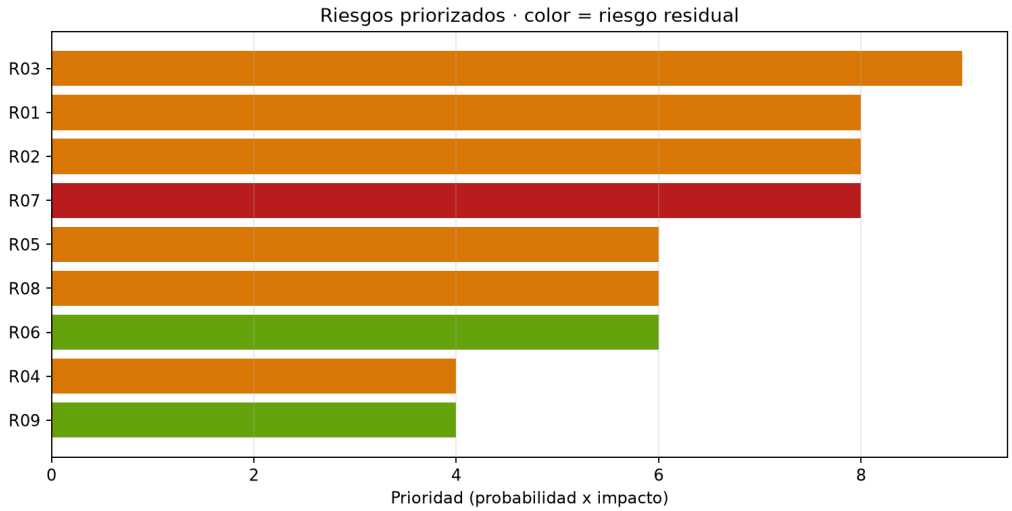
Interesado	Beneficio	Daño posible	Poder	Participación
Affected person	Personas y comunidades que reciben la verificacion: la priorizacion reduce el tiempo de espera del riesgo real	Falsos positivos concentran visitas en una persona o zona sin riesgo; falsos negativos dejan sin verificar un caso de riesgo	low	Canal de apelacion; registro de peticiones y revision humana de cada decision de apertura
Operator	Analistas y coordinadores: reciben una cola ordenada y reduces carga de priorizacion manual	Presion para tratar la lista como orden de ejecucion y perder el juicio profesional en casos dudosos	medium	Formacion y procedimiento que exige registrar la justificacion de cada caso; se auditan las decisiones aun con el modelo
Institutional owner	La direccion del programa: disposicion de la capacidad de verificacion y evidencia para ajustar el diseno	Responsabilidad por decisiones tomadas con un sistema que nadie ha auditado de extremo a extremo	high	Aprobacion explicita de la puesta en marcha; posibilidad de detener el sistema y revision trimestral de resultados
Data team	Equipo tecnico: aprende del feedback de revision y puede corregir el modelo con evidencia	Model drift por cambio de zona o de tasa de reporte; dependencia de una herramienta que nadie audita en profundidad	medium	Monitoreo trimestral; reporte de derivas; y obligacion de reportar riesgos y no alterar el alcance aprobado

2. Registro de riesgos y NIST AI RMF

Nueve riesgos con control, responsable, evidencia y riesgo residual. La prioridad es probabilidad × impacto: ordena la atención, **no** convierte el daño humano en una verdad matemática. Marco: **NIST AI RMF 1.0** (DOI 10.6028/NIST.AI.100-1) — GOVERN (responsable y política), MAP (riesgos documentados), MEASURE (auditoría del LAB12) y MANAGE (condición de retiro y recurso de apelación).

ID	Escenario	L	I	Prioridad	Control	Responsable	Residual
R03	Brecha de recall entre grupos: el grupo con menor recall recibe menos verificacion aunque su tasa base de positivos sea mayor	3	3	9	Auditoria de equidad global; por grupo e interseccional en cada revision y puerta de equidad que degrade a REVIEW	Responsable de equidad (equipo de datos con validacion de la direccion)	medium

ID	Escenario	L	I	Prioridad	Control	Responsable	Residual
R01	Falso positivo: la cola prioriza un caso sin señal de riesgo y desplaza la verificacion real de otro caso	2	4	8	Umbral de priorizacion mas revision humana obligatoria de los 20 primeros casos y muestreo semanal de descartes	Analista de riesgo responsable de la jornada	medium
R02	Falso negativo: un caso con incidente probable no aparece en la cola priorizada y no se verifica a tiempo	2	4	8	Cola secundaria por severidad reportada con revision humana obligatoria y muestreo de casos no priorizados	Coordinador de operacion	medium
R07	Presion operativa para que el DSS decida sin revision humana; erosionando la autoridad del equipo y la trazabilidad	2	4	8	Autoridad limitada a REVIEW; firma humana obligatoria de cada caso priorizado y runbook con procedimiento de detencion	Direccion del programa	high
R05	Reutilizacion del modelo o de la cola priorizada para un fin no aprobado; como surveillance_o evaluacion de personas	2	3	6	Clausula de alcance; revision trimestral de accesos y obligacion de informar cualquier uso nuevo antes de habilitarlo	Direccion del programa	medium
R08	El atributo sensible excluido del modelo deja sesgo indirecto por zona y banda de edad; no visible en la auditoria por grupo	2	3	6	Auditoria interseccional de grupo y banda de edad; y documentacion explicita de que excluir una columna no elimina el sesgo indirecto	Responsable de equidad	medium
R06	El caso sintetico se interpreta como evidencia sobre zonas o grupos reales de Republica Dominicana	3	2	6	Etiqueta visible de caso sintetico en la aplicacion; Dataset Card explicito y nota en el README y en el informe	Equipo de datos	low
R04	Uso indebido del ranking para distribuir fondos o recursos entre zonas; convirtiendo un apoyo preventivo en estigmatizacion territorial	1	4	4	Prohibicion explicita en el alcance; clausula de uso no permitido en la configuracion de gobernanza y revision de actas	Direccion del programa	medium
R09	El sistema recibe datos con identificadores directos o datos personales no previstos en el contrato	1	4	4	Contrato de datos con columnas prohibidas; validacion previa a cualquier prediccion y prohibicion de ingestar campos fuera del esquema	Equipo de datos	low

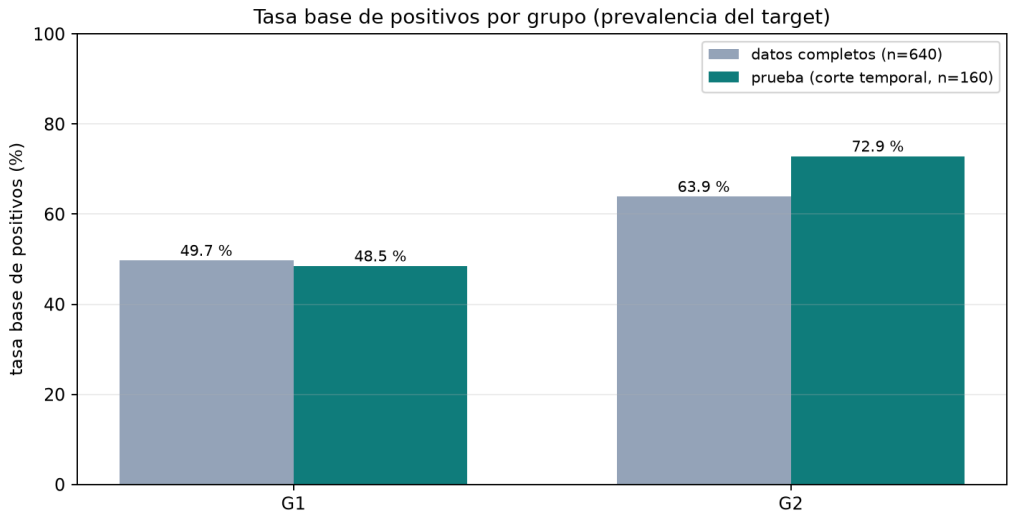


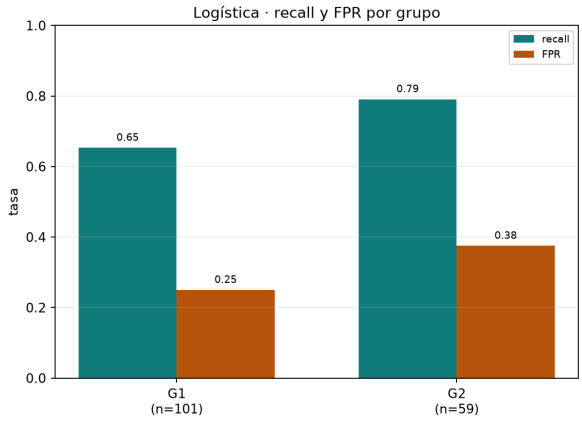
3. Auditoría global, por grupo e interseccional

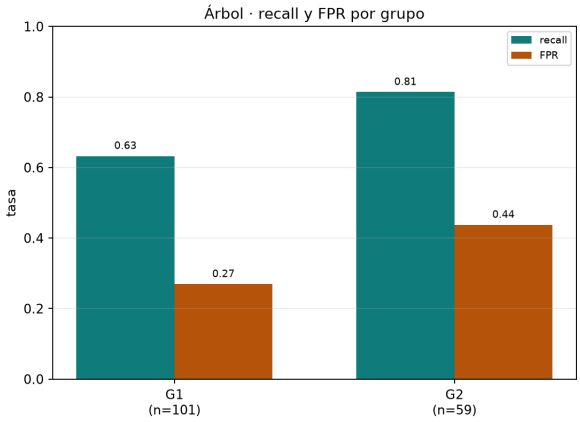
Métrica	Global	G1 (n=101)	G2 (n=59)	Brecha
Accuracy	0.7188	0.7030	0.7458	0.0428
Recall (TPR)	0.7174	0.6531	0.7907	0.1376
FPR	0.2794	0.2500	0.3750	0.1250
Tasa de selección	0.5312	0.4455	0.6780	0.2324
Precisión	0.7765	0.7111	0.8500	0.1389

La diferencia de recall entre grupos (0,1376) refleja en parte la distinta prevalencia del target, no una decisión discriminatoria demostrada: el atributo sensible no entra al modelo. Tasas base de positivos calculadas desde `data/territorial_risk_synthetic.csv` con el corte temporal del repo:

Grupo	Tasa base de positivos en la prueba	Tasa base de positivos en los datos completos
G1	48,5 %	49,7 %
G2	72,9 %	63,9 %

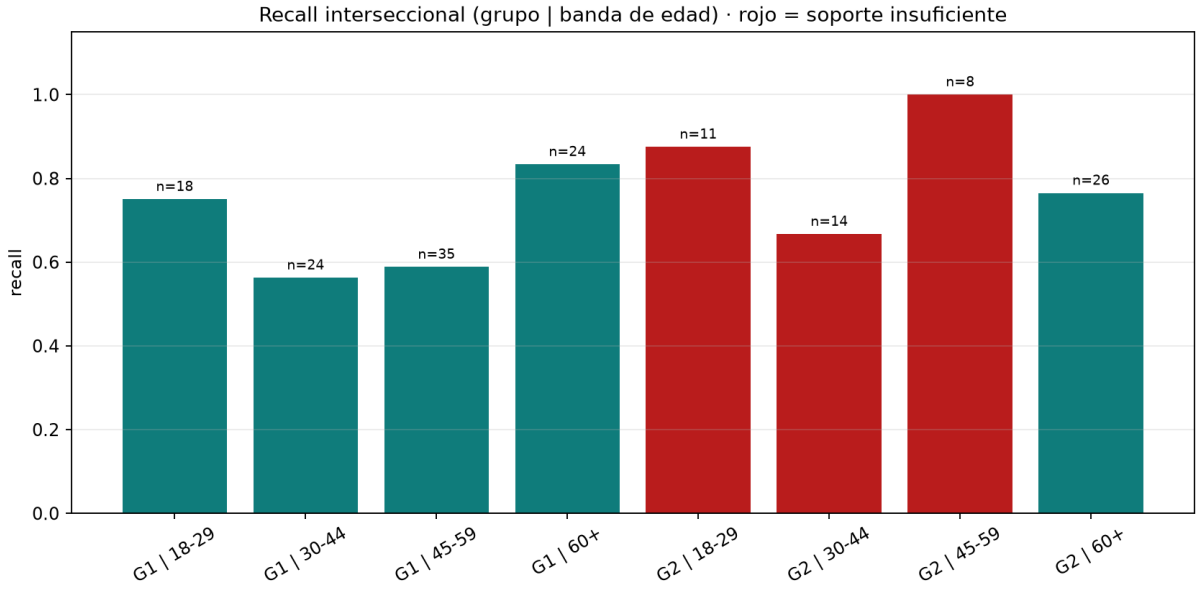






Celdas interseccionales (grupo | banda de edad, modelo logística). Soporte insuficiente en 3 celdas: G2 | 18-29 (n=11), G2 | 30-44 (n=14), G2 | 45-59 (n=8).

Celda	n	Recall	FPR	Soporte
G1 | 18-29	18	0.7500	0.1429	aceptable
G1 | 30-44	24	0.5625	0.1250	aceptable
G1 | 45-59	35	0.5882	0.3889	aceptable
G1 | 60+	24	0.8333	0.2500	aceptable
G2 | 18-29	11	0.8750	0.0000	INSUFICIENTE
G2 | 30-44	14	0.6667	0.5000	INSUFICIENTE
G2 | 45-59	8	1.0000	0.0000	INSUFICIENTE
G2 | 60+	26	0.7647	0.5556	aceptable



4. Decisión y puertas de calidad

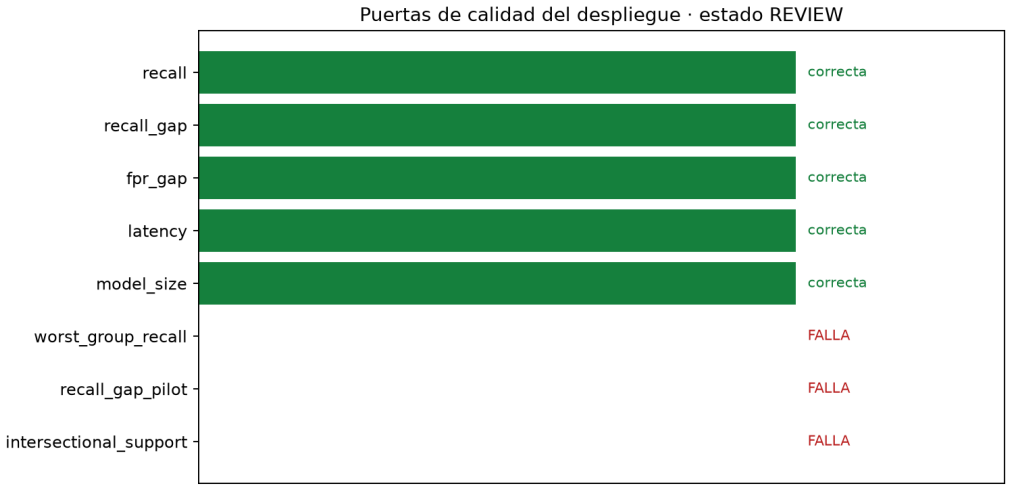
Decisión documentada: LIMITAR — no hay despliegue autónomo; se autoriza un piloto en modo **REVIEW** con revisión humana obligatoria y el baseline sin modelo como camino operativo seguro.

Estado del pipeline: REVIEW — fallan tres puertas: `worst_group_recall` (0,6531 < 0,70), `recall_gap_pilot` (0,1376 > 0,10) e `intersectional_support` (8 < 15).

Escalamiento a STOP: si la brecha de recall supera 0,15 o el recall del peor grupo baja de 0,60, el sistema se retira al baseline sin modelo.

Puerta	Umbral	Observado	Resultado
recall	≥ 0,68	0,7174	cumple
recall_gap	≤ 0,16	0,1376	cumple
fpr_gap	≤ 0,16	0,1250	cumple
latency	≤ 500 ms	verificado en la ejecución	cumple
model_size	≤ 1024 KB	3,56	cumple
worst_group_recall	≥ 0,70	0,6531 (G1)	FALLA
recall_gap_pilot	≤ 0,10	0,1376	FALLA
intersectional_support	≥ 15	8	FALLA

Condición de escalamiento	Umbral	Observado	Estado
stop_recall_gap (brecha de recall)	> 0,15	0,1376	no escala
stop_worst_group_recall (peor grupo)	< 0,60	0,6531	no escala



La evidencia de esta sección es `reports/lab13/deployment_decision.json`, generada por `scripts/lab13_governance.py` a partir de `configs/governance.yml`.

5. Mitigación, trade-offs y decisión

Alternativa	Accuracy	Recall	FPR	Brecha recall	Brecha FPR	Entreno (s, cota)	Modelo (KB)
Logística	0.7188	0.7174	0.2794	0.1376	0.1250	≤ 0,02	3.56
Árbol	0.7063	0.7174	0.3088	0.1813	0.1683	≤ 0,02	7.90



El árbol alcanza la **misma utilidad global** (recall 0,7174) con **brechas mayores** (recall 0,1813 frente a 0,1376; FPR 0,1683 frente a 0,1250) y el **doble de tamaño** (7,90 KB frente a 3,56 KB): el costo adicional no se justifica.

Daño priorizado

Falso negativo: que un caso con incidente probable no llegue a la cola priorizada y la atencion preventiva no se vea a tiempo (las personas que debian recibirla quedan sin verificar). En segundo lugar, el falso positivo que desplaza capacidad de campo hacia casos sin riesgo.

Métrica principal

Brecha de recall (TPR) entre grupos, junto al recall absoluto del grupo con peor desempeño. El recall global 0.7174 no basta: en el grupo G1 el recall es 0.653 frente a 0.791 en G2.

Tolerancia y puerta

Decision documentada: LIMITAR — no hay despliegue autonomo; se autoriza un piloto en modo REVIEW con revision humana obligatoria y el baseline sin modelo como camino operativo seguro. Estado del pipeline: REVIEW — fallan tres puertas: worst_group_recall (0,6531 < 0,70), recall_gap_pilot (0,1376 > 0,10) e intersectional_support (8 < 15). Escalamiento a STOP: si la brecha de recall supera 0,15 o el recall del peor grupo baja de 0,60, el sistema se retira al baseline sin modelo.

Limitaciones

Caso sintetico de 640 registros que no representa personas ni territorios reales. La brecha de recall refleja en parte la tasa base de positivos (G2 63.9 % frente a G1 49.7 % en los datos completos; 72.9 % frente a 48.5 % en la prueba del corte temporal), no una discriminacion causal demostrada: el atributo sensible no entra al modelo, pero zona y banda de edad pueden portar el mismo sesgo de forma indirecta. El soporte interseccional es insuficiente en tres celdas (n=8, n=11 y n=14), hay una sola particion temporal y una sola semilla, y no se calcularon intervalos de confianza; ademas, el limite de decision depende del coste real de un falso negativo, que en este caso sintetico no esta cuantificado.

Recomendación

Decision documentada: LIMITAR — no hay despliegue autonomo; se autoriza un piloto en modo REVIEW con revision humana obligatoria y el baseline sin modelo como camino operativo seguro. Estado del pipeline: REVIEW — fallan tres puertas: worst_group_recall (0,6531 < 0,70), recall_gap_pilot (0,1376 > 0,10) e intersectional_support (8 < 15). Escalamiento a STOP: si la brecha de recall supera 0,15 o el recall del peor grupo baja de 0,60, el sistema se retira al baseline sin modelo. La logistica es la unica configuracion (misma utilidad global que el arbol, brechas menores y modelo mas pequeno). Antes de cualquier uso con datos reales hay que repetir la auditoria con datos de un periodo posterior, con intervalos de confianza y con el coste del dano cuantificado; y mantener como condicion de retiro que exista capacidad de revision humana y que el caso siga siendo sintetico y documentado.

Obligación legal, marco voluntario y recomendación ética. En este caso sintético no hay una obligación legal específica que se pueda verificar (no hay datos personales ni decisiones reales), y esa ausencia se documenta en lugar de suplirse con el marco técnico: el **NIST AI RMF 1.0** (marco voluntario) organiza el control —GOVERN, MAP, MEASURE, MANAGE— y la **recomendación ética** (alternativa no predictiva, recurso de apelación, condición de retiro) sostiene la decisión. Ninguna de las dos sustituye a la revisión jurídica que cualquier uso con datos reales exigiría.

Uso responsable de IA. El asistente de IA (Kilo, modelo MiniMax-M3) apoyó la estructura de los artefactos, la redacción de las tarjetas y la corrección de dos scripts del proyecto base que no compilaban (`lab11_impact.py` y `simulate_incident.py`, por saltos de línea reales dentro de literales), y después una revisión de coherencia de la entrega: unificar la decisión (LIMITAR) con el estado real del pipeline (REVIEW), derivar las tasas base de positivos de los datos, marcar las celdas con soporte insuficiente y reconstruir las tablas ilegibles de la página 1. Los **valores del análisis** —finalidad, interesados, probabilidad e impacto de cada riesgo, tolerancia, métrica principal y recomendación— los decidió el estudiante con la evidencia del manual y de las ejecuciones; el asistente no inventó ninguna cifra ni referencia. Detalle en `docs/AI_USE_DECLARATION.md`.

Referencias. NIST, *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*, DOI 10.6028/NIST.AI.100-1 · OECD, *Recommendation of the Council on Artificial Intelligence*, DOI 10.1787/cc2e1d3e-en · Fairlearn Contributors, *Performing a Fairness Assessment* (documentación oficial).